



**Universidade do Minho**

Escola de Engenharia

Departamento de Produção e  
Sistemas

# Filas de Espera

Elsa Silva

*elsa@dps.uminho.pt*

# Índice

- Resultados de aprendizagem
- Caracterização geral
- Exemplos
- Motivação
- Caracterização de sistemas de filas de espera
- Conceitos básicos e notação
- Relações fundamentais
- Exemplos
- Notação de Kendall
- Filas de espera de Markov
- Exemplos
- Considerações finais
- Áreas e tópicos relacionados
- Bibliografia e links

# Resultados de aprendizagem

- **Caracterizar** um sistema que possa ser modelado através da teoria das filas de espera.
- Obter as **medidas de desempenho** fundamentais com base nas probabilidades de estado e nas fórmulas de Little.
- Obter as **medidas de desempenho fundamentais** com base em fórmulas para as filas de espera mais simples (**M/M/1 e M/M/s**).
- **Sugerir alterações** a sistemas de filas de espera com base nas medidas de desempenho e nos custos de diferentes configurações / parâmetros.

# Caracterização geral

- De forma geral, está-se perante um sistema que pode ser modelado através da **teoria das filas de espera** quando, ao longo do tempo, várias entidades pretendem utilizar um serviço, não sendo garantido que a **capacidade de prestação do serviço** é suficiente para todas as entidades serem atendidas logo que o desejem.
- Em teoria das filas de espera, as entidades que procuram o serviço designam-se por **clientes** e as entidades que prestam o serviço por **servidores**.
- A fila de espera pode ser física ou conceptual.
- Exemplos de sistemas que podem ser modelados através de filas de espera:
  - Caixas multibanco;
  - Urgências de hospitais;
  - Filas de espera para cirurgias;
  - Emergência médica.

# Exemplos

<b>Clientes</b>	<b>Serviço</b>	<b>Servidor(es)</b>
Pessoas	Operações bancárias (caixa automática)	Caixas automáticas
Pacientes	Urgência médica (hospital)	Equipas de urgência
Pacientes	Cirurgia	Equipas cirúrgicas
Compradores	Compra de bens em lojas	Vendedores
Telefonemas	Atendimento telefónico ( <i>call center</i> )	Colaboradores
Mensagens	Encaminhamento em redes de computadores	<i>Router</i>
Aviões	Aterragem (aeroporto)	Pistas de aeroporto
Barcos	Descarregamento / Carregamento (porto marítimo)	Guindastes
Carros	Travessia marítima	Ferry boat
Máquinas	Reparação/Preparação	Operadores
Encomendas	Processamento	Linhas de produção
Tarefas	Processamento	Processador (de computador)
Falha de stock	Entrega de produto	Fornecedores
Veículos	Deslocação viária	Cruzamentos / rotundas
Pessoas	Transporte / deslocação	Taxis

# Motivação (1)

## Abastecimento de combustível numa única bomba

- **Cenário determinístico 1**

- Chega um cliente exactamente de **15 em 15 minutos** → taxa de chegada é de **4 clientes por hora**
- Cada cliente demora exactamente **10 minutos** a ser atendido → taxa de serviço é de **6 clientes por hora**
- **Nunca há fila de espera!**
- Proporção de tempo que o servidor está ocupado é **2/3**




- **Cenário determinístico 2**

- Chega um cliente exactamente de **15 em 15 minutos** → taxa de chegada é de **4 clientes por hora**
- Cada cliente demora exactamente **20 minutos** a ser atendido → taxa de serviço é de **3 clientes por hora**
- **Fila de espera nunca pára de crescer!**
- Servidor está sempre ocupado

## Motivação (2)

Simulação do comprimento da fila ao longo de 500 minutos para os cenários 1, 2 e 3 (Daellenbach and McNickle, 2005)

- **Cenários estocásticos**
  - Tempo entre chegadas segue uma **distribuição de probabilidade** (exponencial negativa) com **valor esperado de 15 minutos**
  - Tempo de serviço segue uma **distribuição de probabilidade** (exponencial negativa) com **valor esperado de 5 minutos** (cenário 1), **10 minutos** (cenário 2), **12 minutos** (cenário 3)
- Exemplos de questões relevantes (a serem respondidas no seguimento destas notas):
  - **Qual o comprimento médio da fila?**
  - **Em média, quanto tempo tem de esperar um cliente para ser atendido?**

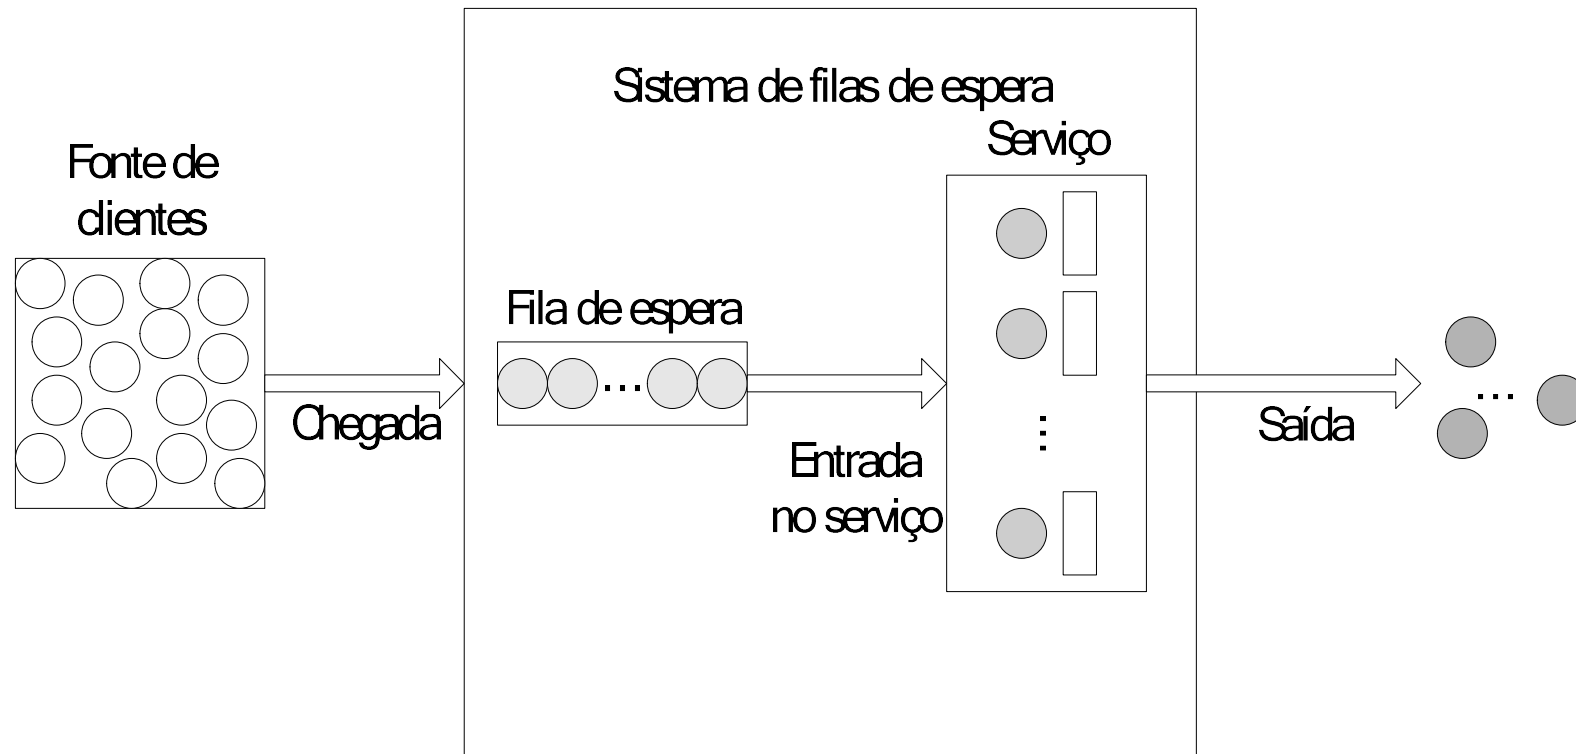


## Motivação (3)

- Sistemas de filas de espera podem ser estudados como uma **sequência de eventos aleatórios** em que a distribuição de probabilidade de cada evento é conhecida / pressuposta / estimada
- **Vantagens**
  - Análise é exclusivamente teórica (esforço dispendido na obtenção de resultados é muito reduzido)
  - Análise é simples
- **Desvantagens**
  - Simplificações do sistema para permitir tratamento por modelos filas de espera podem ser significativas (quando comparados, por exemplo, com modelos de simulação)
- **Cuidados a ter**
  - Pressupostos podem ser abusivos



# Caracterização de sistemas de filas de espera (1)



- Questão fundamental: **qualidade do serviço vs. custo do serviço**
  - Um extremo: **sistema rarefeito** (servidores muito pouco ocupados)
  - Outro extremo: **sistema congestionado** (servidores muito ocupados)

# Caracterização de sistemas de filas de espera (2)

- **Fonte** (gera clientes que chegam ao sistema)
  - **Número de fontes**
    - no caso de haver tratamento para diferentes grupos, a cada grupo deverá ser associada uma fonte
  - **Dimensão da população**
    - finita (importante considerar quando o número de clientes no sistema influencia o padrão das chegadas)
    - Infinita
  - **Dimensão da chegada**
    - simples
    - em grupo
  - **Controlo das chegadas**
    - controláveis
    - incontroláveis

# Caracterização de sistemas de filas de espera (3)

- **Padrão das chegadas** (distribuição do tempo entre chegadas)
  - constante
  - aleatória
    - observação experimental
    - distribuição de probabilidade teórica
- **Taxa de chegada** ( $\lambda$ , número médio de clientes que procuram o serviço por unidade de tempo)
  - pode depender ou não do número de clientes no sistema
- **Atitude dos clientes**
  - paciente
  - impaciente

# Caracterização de sistemas de filas de espera (4)

- **Fila** (clientes que esperam o atendimento)
  - **Número de filas**
    - nenhuma
    - única
    - uma por servidor
  - **Comprimento máximo da fila**
    - capacidade virtualmente infinita
    - Finita
  - **Disciplina da fila**
    - FIFO – first in first out
    - LIFO – last in first out
    - com prioridades
    - aleatória

# Caracterização de sistemas de filas de espera (5)

- **Serviço (postos de atendimento)**
  - **Configuração**
    - servidores em paralelo
      - conjunto de servidores iguais, cada servidor atende um cliente de cada vez, cliente só é atendido por um servidor
    - fases (servidores em sequência)
      - o atendimento de um tipo só pode ser feito depois do atendimento de outro tipo terminar (cada fase pode ter servidores em paralelo)
    - redes de filas de espera
      - “percurso” dos clientes não é estruturado
  - **Dimensão do serviço**
    - simples
    - em grupo

# Caracterização de sistemas de filas de espera (6)

- **Padrão do serviço** (distribuição do tempo de serviço)
  - constante
  - aleatória
    - observação experimental
    - distribuição de probabilidade teórica
- **Taxa de serviço** ( $\mu$ , número médio de clientes que podem ser atendidos num servidor por unidade de tempo)
  - pode depender ou não do número de clientes no sistema

# Caracterização de sistemas de filas de espera (7)

- Excepto quando referido algo em contrário considera-se
  - **Chegadas simples, incontroláveis, aleatórias, com taxa independente do número de clientes no sistema e clientes pacientes**
  - **Uma única fase com servidores paralelos e idênticos, tempo de serviço aleatório, com taxa de serviço independente do número de clientes no sistema**
- O sistema em regime permanente (por oposição a regime transitório): o seu estado é independente do estado inicial

# Caracterização de sistemas de filas de espera (8)

- Exemplo: uma **caixa automática**

		Modelo
<b>Fonte</b>	<b>Clientes</b>	Todas as pessoas*
	<b>Número de fontes</b>	Uma
	<b>Dimensão da população</b>	Infinita*
	<b>Dimensão da chegada</b>	Simples*
	<b>Controlo das chegadas</b>	Incontroláveis
	<b>Padrão das chegadas</b>	Aleatório
	<b>Taxa de chegada</b>	Não depende do número de clientes no sistema
	<b>Atitude dos clientes</b>	Paciente*
<b>Fila</b>	<b>Número</b>	Uma
	<b>Capacidade</b>	Infinita
	<b>Disciplina</b>	FIFO
<b>Serviço</b>	<b>Configuração</b>	Uma fase com um servidor
	<b>Dimensão</b>	Simples
	<b>Padrão do serviço</b>	Aleatório
	<b>Taxa de serviço</b>	Não depende do número de clientes no sistema



# Conceitos básicos e notação (1)

- **Estado do sistema:** número total de clientes no sistema (número de clientes na fila mais o número de clientes a serem atendidos)
  - $\lambda$  - **taxa de chegada** (número médio de clientes que procuram o serviço por unidade de tempo)
  - $1/\lambda$  - **tempo médio entre chegadas** (tempo médio entre duas chegadas seguidas)
  - $\mu$  - **taxa de serviço** (número médio de clientes que podem ser atendidos por unidade de tempo) de um servidor
  - $1/\mu$  - **tempo médio de serviço**
  - $s$  - **número de servidores** (paralelos)
  - $\rho$  - **intensidade de tráfego** (ou taxa de ocupação) – fracção de tempo que *cada* servidor está ocupado
    - $\rho = \lambda / (s\mu)$
    - Se  $\rho \geq 1$  a fila aumenta indefinidamente, logo não existe regime permanente

# Medidas de desempenho fundamentais

- $W$  - tempo médio (de permanência de um cliente) no sistema
- $W_q$  - tempo médio (de espera) na fila
- $W_s$  - tempo médio de atendimento,  $W_s = 1/\mu$

$$W = W_q + W_s$$

- $L$  - número médio de clientes no sistema
- $L_q$  - número médio de clientes na fila (comprimento médio da fila)
- $L_s$  - número médio de clientes a serem atendidos

$$L = L_q + L_s$$

- $\pi_n$  probabilidade de estarem  $n$  clientes no sistema (ou fracção de tempo em que estão  $n$  clientes no sistema)

# Relações fundamentais

- $K$ : capacidade do sistema (número máximo de clientes no sistema)
  - se um cliente chega ao sistema e já estão  $K$  clientes no sistema, o cliente não entra
  - se o sistema não tiver limite de capacidade,  $K = \infty$

$$L = \sum_{n=0}^K n \pi_n \quad L_q = \sum_{n=s+1}^K (n-s) \pi_n \quad L_s = \sum_{n=0}^{s-1} n \pi_n + s \left[ \sum_{n=s}^K \pi_n \right]$$

- **Fórmulas de Little**

$$\begin{aligned} L &= \lambda W \\ L_q &= \lambda W_q \end{aligned}$$

## Exemplo (1)

- Uma tabacaria tem um **único funcionário** que demora, em média, **0.5 minutos a atender** um cliente. Em média, a tabacaria **tem 20 clientes por hora**.
  - 1. Quantos clientes podem ser atendidos por hora?
  - 2. Qual o tempo médio entre chegadas?
  - 3. O funcionário trabalha 8 horas por dia. Quanto tempo está ocupado?
- 
- 1.  $1/\mu = 0.5$  minutos  
 $\mu = 2$  clientes / minuto = 120 clientes/hora
  - 2.  $\lambda = 20$  clientes / hora  
 $1/\lambda = 0.05$  horas = 3 minutos
  - 3.  $\rho = \lambda / \mu = 20 / 120 = 0.167$   
*Tempo ocupado por dia =  $0.167 * 8$  horas = 1.333 horas*

## Exemplo (2)

- Um centro de atendimento telefónico ao cliente tem **três colaboradores e seis linhas de atendimento**
- Quando um cliente telefona pode
  - ser logo atendido (se algum colaborador estiver disponível),
  - ter de esperar ocupando uma linha (se os colaboradores estiverem todos ocupados mas existirem linhas livres),
  - ou não conseguir a ligação (se não existirem linhas disponíveis).
- Uma estimativa das probabilidades associadas a cada um dos possíveis estados do sistema é dada na tabela seguinte

Estado, $n$	0	1	2	3	4	5	6
Probabilidade, $\pi_n$	0.068	0.170	0.212	0.177	0.147	0.123	0.103

## Exemplo (2)

1. Qual a probabilidade de todos os colaboradores estarem desocupados?
2. Qual a probabilidade de um cliente não ter de esperar?
3. Qual a probabilidade de um cliente esperar na fila?
4. Qual a probabilidade de um cliente não conseguir ligação?

1.  $\pi_0 = 0.068$
2.  $\pi_0 + \pi_1 + \pi_2 = 0.45$
3.  $\pi_3 + \pi_4 + \pi_5 = 0.447$
4.  $\pi_6 = 0.103$

## Exemplo (3)

- Um estação dos correios tem **três balcões**. O tempo médio entre-chegadas de clientes é de **30 segundos** e estes demoram, em média, **1.25 minutos a serem atendidos**. Em média, um cliente passa **3 minutos na estação dos correios**.

1. Qual o número médio de clientes no sistema?
2. Qual a percentagem de tempo que os colaboradores dos correios estão desocupados?

- $s = 3$
- $1/\lambda = 0.5 \text{ minutos/cliente}$
- $1/\mu = 1.25 \text{ minutos/cliente}$
- $W = 3 \text{ minutos}$

1.  $L = \lambda W = 6 \text{ clientes}$
2.  $\lambda = 2 \text{ clientes/minuto}$   
 $\mu = 0.8 \text{ clientes/minuto}$

*Proporção que um servidor está ocupado é  $\rho$ , logo a proporção desocupado é:*

$$1 - \rho = 1 - \lambda / (s \mu) = 0.167, \text{ logo a percentagem é } 16.7\%.$$

# Notação de Kendall (1)

- **Notação de Kendall:  $a / b / c / d / e / f$**

- **$a$  : Tempo entre-chegadas dos clientes**

- M : distribuição exponencial;
    - D : determinístico;
    - G : distribuição geral ou arbitrária;
    - ...

- **$b$  : Tempo de serviço**

- M : distribuição exponencial;
    - D : determinístico;
    - G : distribuição geral ou arbitrária;
    - ...

- **$c$  : Número de servidores**



# Notação de Kendall (2)

- **$d$ : Capacidade do Sistema**
- **$e$ : Dimensão da população de clients**
- **$f$ : Disciplina da fila**
  - FIFO (*First In First Out*);
  - LIFO (*Last In First Out*);
  - esquemas de prioridade;
  - ...
- Exemplos
  - $M / M / 1 / \infty / \infty / \text{FIFO}$
  - $M / M / 5$
  - $M / D / 2 / 7 / \infty / \text{FIFO}$

# Filas de espera de Markov (1)

- **M / M / ...**
- Se o tempo entre-chegadas e o tempo de serviço seguem a **distribuição exponencial negativa** está-se perante uma fila de espera de **Markov**
- Para várias filas de espera de Markov é possível derivar as **probabilidades de estado** ( $\pi_0, \pi_1, \pi_2, \pi_3, \dots$ ) e com base nessas probabilidades obter **fórmulas fechadas para** o número esperado de clientes e tempos esperados (em regime permanente)
- **Tempo entre chegadas com distribuição exponencial negativa**
  - Chegadas são **independentes** (clientes não estão relacionados)
  - Tempo até à próxima chegada é **independente** do tempo que decorreu desde a última chegada
  - **Tempos entre chegadas curtos são mais frequentes** que entre chegadas longos


## Filas de espera de Markov (2)

- M / M / ...
- **Tempo de serviço com distribuição exponencial negativa**
  - Tempo **até à conclusão serviço não depende do tempo que já passou** (se já passou muito tempo, não quer dizer que o atendimento esteja quase a acabar mas sim que o cliente tem alguma característica que o torna o seu atendimento mais demorado)
  - **Muitos clientes são atendidos depressa** e poucos demoram muito tempo

## Filas de espera de Markov (3)

- Função densidade de probabilidade da distribuição exponencial com parâmetro  $\lambda$

- $$f_T(t) = \begin{cases} \lambda e^{-\lambda t}, & \text{para } t \geq 0 \\ 0, & \text{para } t \leq 0 \end{cases}$$



- Valor esperado  $\mathbf{E(T) = 1/\lambda}$
- Probabilidades acumuladas ( $t > 0$ )

$$P\{T \leq t\} = 1 - e^{-\lambda t}$$

$$P\{T > t\} = e^{-\lambda t}$$

## Filas de espera de Markov (4)

- A probabilidade de ocorrerem **valores pequenos é maior** do que a probabilidade de ocorrerem valores próximos do valor esperado  
 $E(T) = 1/\lambda$
- A distribuição exponencial **não tem memória** (por exemplo, se o tempo entre-chegadas segue uma distribuição exponencial, o tempo até à próxima chegada não é influenciado pelo tempo que já decorreu desde a última chegada)
  - $P\{T > t + \Delta t \mid T > \Delta t\} = P\{T > t\}$

## Filas de espera de Markov (6)

- Resultados a serem apresentados para as filas de espera M/M/1 e M/M/s **são válidos** para qualquer disciplina da fila (FIFO, LIFO, ...) desde que
  - Todos os clientes **permaneçam na fila** depois de nela entrarem (clientes são pacientes);
  - O **tempo de serviço médio seja igual** para todos os clientes;
  - O **servidor acabe de atender o cliente antes de começar a atender** o seguinte (não há interrupções);
  - Se houver clientes em espera, um **servidor que acabe de atender um cliente passa imediatamente a atender outro**.

## Filas de espera de Markov (7)

- Resultados para uma fila de espera M / M / 1

$$\rho = \lambda / \mu$$

$$\pi_0 = 1 - \rho$$

$$\pi_n = \rho^n \pi_0 = \rho^n (1 - \rho), n \geq 1$$

$$L_q = \frac{\rho^2}{1 - \rho}$$

$$L_s = \rho$$

$$L = \frac{\rho}{1 - \rho}$$

$$W_q = \frac{\rho}{\mu(1 - \rho)}$$

$$W_s = 1 / \mu$$


$$W = \frac{1}{\mu(1 - \rho)}$$

- Probabilidade do tempo de permanência na fila exceder o valor  $t$

$$W_q(t) = \begin{cases} \rho, & \text{para } t = 0 \\ \rho e^{-\mu(1-\rho)t}, & \text{para } t \geq 0 \end{cases}$$

## Filas de espera de Markov (8)

- Tempo esperado na fila vs. intensidade de tráfego.





## Filas de espera de Markov (9)

- Resultados para uma fila de espera M / M / s

$$\rho = \frac{\lambda}{s\mu}$$

$$\pi_0 = \left[ \frac{(s\rho)^s}{s!(1-\rho)} + \sum_{n=0}^{s-1} \frac{(s\rho)^n}{n!} \right]^{-1}$$

$$\pi_n = \begin{cases} \frac{(s\rho)^n \pi_0}{n!}, & \text{para } 1 \leq n \leq s \\ \frac{s^s \rho^n \pi_0}{s!}, & \text{para } n \geq s \end{cases}$$

- Probabilidade de todos os servidores estarem ocupados

$$P_B = \frac{\pi_s}{1-\rho}$$

# Filas de espera de Markov (10)

- Resultados para uma fila de espera M / M / s

$$L_q = \frac{s^s \rho^{s+1} \pi_0}{s! (1-\rho)^2}$$
$$L_s = \lambda / \mu$$
$$L = L_q + L_s$$

$$W_q = L_q / \lambda$$
$$W_s = 1 / \mu$$
$$W = W_q + W_s$$

- Probabilidade do tempo de espera na fila exceder o valor  $t$

$$W_q(t) = \begin{cases} 1 - \frac{(s\rho)^s \pi_0}{s! (1-\rho)}, \text{ para } t = 0 \\ \frac{(s\rho)^s \pi_0}{s! (1-\rho)} e^{-s\mu(1-\rho)t}, \text{ para } t > 0 \end{cases}$$

# Filas de espera de Markov (11)

- Outras filas de espera de Markov para as quais há resultados estabelecidos:
  - $M/M/1/K$
  - $M/M/s/K$
  - $M/M/s/K/N$
- Exemplos de filas de espera não-Markovianas para as quais também há resultados estabelecidos:
  - $M/G/1$
  - $M/D/1$
  - $M/D/s$
  - $GI/G/1$
  - $GI/G/s$
  - ...

## Exemplo (4)

- Num determinado processo produtivo, todas as peças têm de passar por uma determinada máquina. Esta **demora, em média, 30 segundos a processar** uma peça. O tempo **médio entre-chegadas de peças à máquina é de 40 segundos**. A gestão da fábrica pretende que, por razões de espaço, em 90% do tempo não haja mais de três peças em espera e que não mais de 10% das peças esperem mais de um minuto para serem processadas pela máquina. Assuma que os tempos entre-chegadas e de serviço seguem a distribuição exponencial.
1. Na situação actual, as metas colocadas pela gestão estão a ser cumpridas?
  2. Qual o efeito da compra de uma nova máquina (idêntica) que funcione em paralelo com a existente?

## Exemplo (4)

- Situação actual
  - $M / M / 1$
  - $\lambda = 1.5 \text{ peças / minuto}$
  - $\mu = 2 \text{ peças / minuto}$
  - Probabilidade de estarem mais de três peças em espera =  
 $= \pi_5 + \pi_6 + \pi_7 + \pi_8 + \dots = 1 - (\pi_0 + \pi_1 + \pi_2 + \pi_3 + \pi_4) =$   
 $= 0.237$   
Em 76.3% do tempo não há mais de três peças em espera. A gestão pretendia que esse valor fosse de 90%.
  - $W_q(1) = 0.455.$
  - 45.5 % das peças esperam mais de 1 minuto para serem processadas. A gestão pretendia que esse valor fosse de 10%.

## Exemplo (4)

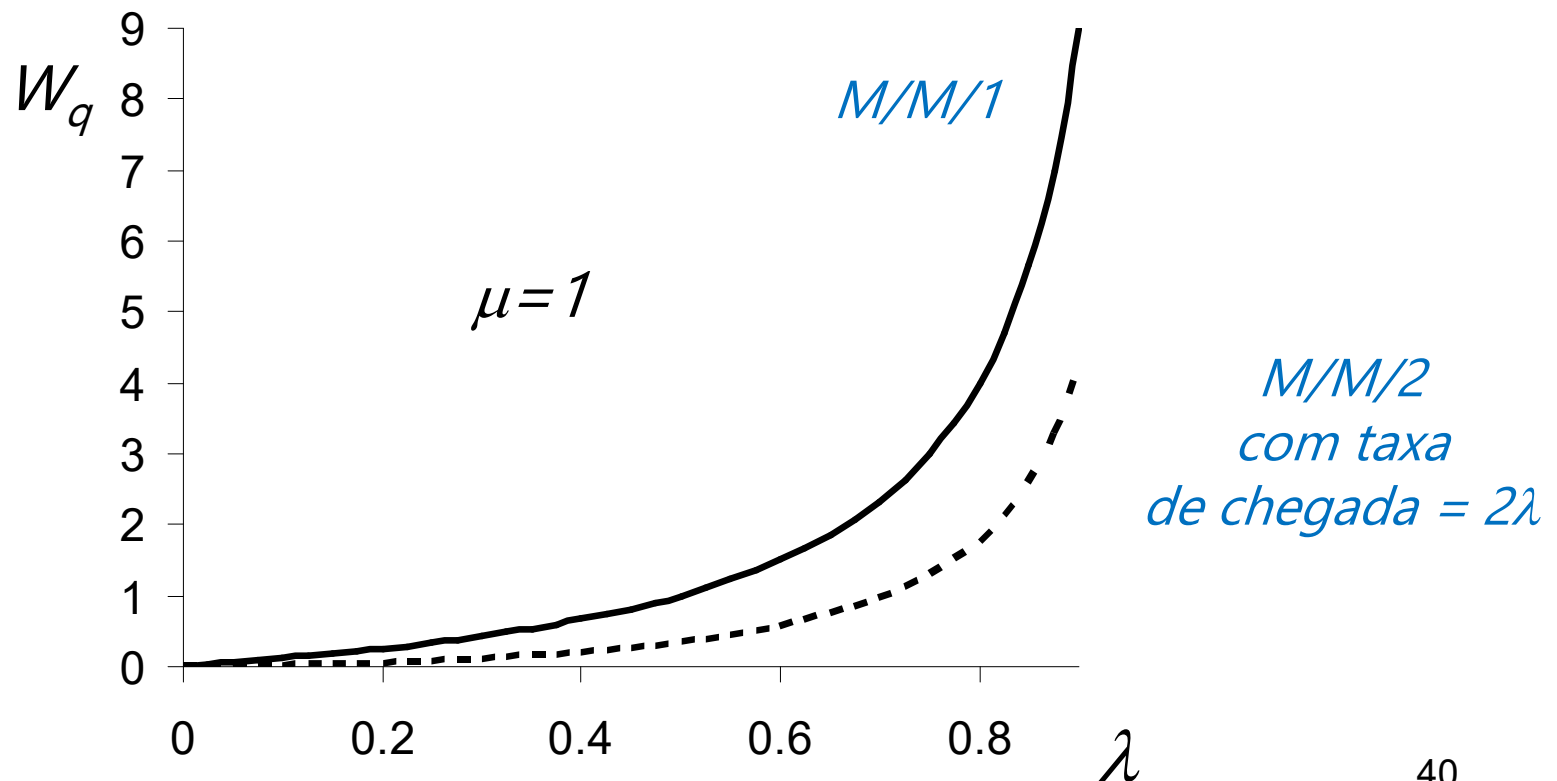
- Com uma nova máquina
  - $M / M / s$
  - $s = 2$
  - $\lambda = 1.5 \text{ peças / minuto}$
  - $\mu = 2 \text{ peças / minuto}$
  - Probabilidade de estarem mais de três peças em espera =  
 $= \pi_6 + \pi_7 + \pi_8 + \dots = 1 - (\pi_0 + \pi_1 + \pi_2 + \pi_3 + \pi_4 + \pi_5) =$   
 $= 0.004$   
Em 99.6% do tempo não há mais de três peças em espera, o que cumpre a meta da gestão.
  - $W_q(1) = 0.0167$ .
  - 1.67 % das peças esperam mais de 1 minuto para serem processadas, o que cumpre a meta da gestão.

## Exemplo (5)

- Compare o tempo esperado na fila para as duas situações seguintes para diferentes valores da taxa média de chegada.
1. **Dois servidores cada um deles com uma fila** de espera (como, por exemplo, o que acontece num supermercado com duas caixas abertas).
  2. **Dois servidores com uma fila única** (como, por exemplo, o que acontece em balcões de atendimento com senhas numeradas).
- Considere que a taxa média de atendimento de um servidor é de 1 cliente / unidade de tempo em ambas as situações.

## Exemplo (5)

1. **Dois sistemas M/M/1 em paralelo** (tempo de espera começa a degradar-se muito a partir de uma taxa de chegada de cerca 1.4 que corresponde a 0.7 para cada fila).
2. **Um sistema M/M/2** (tempo de espera começa a degradar-se muito a partir de uma taxa de chegada de cerca 1.6).





## Exemplo (6)

- Numa estação de correios de uma pequena vila chegam à estação **4 clientes por hora**. Atualmente a estação tem apenas um funcionário a atender os clientes e estimou-se que o funcionário atende em média **5 clientes por hora**.  
Considere que o pressuposto de se tratar de um sistema de filas de espera de Markov é aceitável.

### Dados:

M/M/1

$s = 1$

$\lambda = 4$  clientes/ hora

$\mu = 5$  clientes / hora

$1/\lambda = 1/4 = 0,25$  entra um cliente na estação a cada 0,25 horas, ou seja a cada 15 minutos

$1/\mu = 1/5 = 0,2$  o funcionário demora em media 0,2 horas a atender, ou seja 12 minutos

## Exemplo (6)

- **Medidas de desempenho**

$$\rho = \lambda / \mu = 4 / 5 = 0,8 = 80\% \quad \text{Taxa de ocupação}$$

$$L_q = \frac{\rho^2}{1-\rho} = \frac{4/5^2}{1-\frac{4}{5}} = 3,2 \rightarrow \text{clientes em média na fila à esperade serem atendidos}$$

$$L_s = \frac{\lambda}{\mu} = \frac{4}{5} = 0,8 \rightarrow \text{número médio de clientes a serem atendidos}$$

$$L = L_q + L_s = 3,2 + 0,8 = 4 \rightarrow \text{número médio de clientes na estação dos correios}$$

$$W_q = \frac{L_q}{\lambda} = \frac{3,2}{4} = 0,8 \text{ horas} = 48 \text{ minutos} \rightarrow \text{Tempo médio de espera para serem atendidos}$$

## Exemplo (7)

- Considere agora que a estação de correios passa a ter **2 funcionários** e se mantém o sistema de **fila única**.

### Dados:

- $M/M/1$
- $s = 2$
- $\lambda = 4 \text{ clientes/hora}$
- $\mu = 5 \text{ clientes/hora}$
- $1/\lambda = 1/4 = 0,25$  entra um cliente na estação a cada 0,25 horas, ou seja a cada 15 minutos
- $1/\mu = 1/5 = 0,2$  cada funcionário demora em media 0,2 horas a atender, ou seja 12 minutos

## Exemplo (7)

- Medidas de desempenho

$$\rho = \frac{\lambda}{s\mu} = \frac{4}{2 \times 5} = 0,4 = 40\% \text{ Taxa de ocupação}$$

$$\pi_0 = 0,4286 \rightarrow \text{Probabilidade de estarem } \mathbf{0} \text{ clientes no sistema}$$

$$L_q = 0,1524 \rightarrow \text{clientes em média na fila à esperade serem atendidos}$$

$$W_q = \frac{L_q}{\lambda} = \frac{0,1524}{4} = 0,0381 \text{ horas} = 2,286 \text{ minutos} \rightarrow \text{Tempo médio de espera para o cliente ser atendido}$$

## Exemplo (8)

- Considere agora que a estação de correios passa a ter **2 funcionários, mas cada um com uma fila**

### Dados:

- 2 sistemas M/M/1
- $s = 1$
- $\lambda = 2 \text{ clientes/hora}$  -> reduziu-se a taxa de chegada para metade
- $\mu = 5 \text{ clientes/hora}$
- $1/\lambda = 1/2 = 0,5$  entra um cliente na estação a cada 0,5 horas, ou seja a cada 30 minutos
- $1/\mu = 1/5 = 0,2$  cada funcionário demora em media 0,2 horas a atender, ou seja 12 minutos

## Exemplo (8)

- **Medidas de desempenho**

$$\rho = \lambda / \mu = 2 / 5 = 0,4 = 40\% \quad \text{Taxa de ocupação}$$

$$L_q = \frac{\rho^2}{1-\rho} = \frac{2/5^2}{1-\frac{2}{5}} = 0,267 \rightarrow \text{clientes em média na fila à espera de serem atendidos}$$

$$W_q = \frac{L_q}{\lambda} = \frac{0,267}{2} = 0,133 \text{ horas} = 7,98 \text{ minutos} \rightarrow \text{Tempo médio de espera para o cliente ser atendido}$$

# Comparação

Medida de desempenho	M/M/1	M/M/2	2 sistemas M/M/1
$\rho$	80%	40%	40%
$L_q$	3,2 clientes	0,15 clientes	0,27 clientes
$W_q$	48 minutos	2,29 minutos	7,98 minutos

## Comentários finais

- **Modelos da teoria das filas de espera auxiliam na análise e/ou dimensionamento de sistemas**
- **Sistema pode ser mais eficiente**
  - **Aumentando o número de servidores** (o que, tipicamente, acarreta investimentos significativos)
  - **Aumentando a taxa de serviço**
  - **Formando uma fila para todos os servidores em vez de uma fila por servidor** (para servidores (idênticos) em paralelo)
  - **Reduzindo a variabilidade do tempo de serviço** (por exemplo, tornando o serviço mais repetitivo)
- Medidas para controlar (influenciar) a taxa de chegada (e/ou reduzir a sua variabilidade) podem ser muito benéficas
  - **Por exemplo, descontos nas horas de vazio**



# Áreas e tópicos relacionados

- **Redes de filas de espera**
- **Processos estocásticos e processos Markovianos**
  - Um sistema de fila de espera é um caso particular de um processo estocástico.
- **Simulação**
  - Permite analisar sistemas de filas de espera para os quais não existem resultados analíticos (entre muitas outras coisas...).

## Bibliografia e *links*

- H. G. Daellenbach and D. C. McNickle, Management Science - Decision Making Through Systems Thinking, Palgrave MacMillan, 2005.
- S. Hillier and G. J. Lieberman, Introduction to Operations Research, McGrawHill, 2005.
- P. A. Jensen and J. F. Bard, Operations Research - Models and Methods, John Wiley and Sons, 2003.
- A. M. Law and W. D. Kelton, Simulation Modeling and Analysis, McGrawHill, 2000.
- L. V. Tavares, R. C. Oliveira, I. H. Themido, F. N. Correia, Investigação Operacional, McGraw Hill, 1996.
- [\*http://www.usm.maine.edu/math/JPQ/\*](http://www.usm.maine.edu/math/JPQ/)
- [\*http://www.me.utexas.edu/~jensen/ORMM/frontpage/jensen.lib/index.html\*](http://www.me.utexas.edu/~jensen/ORMM/frontpage/jensen.lib/index.html)