OpenMP

Arquitetura de Computadores Mestrado Integrado em Engenharia Informática

Material de Apoio

 Tutoriais, exemplos e material diverso no site oficial: http://www.openmp.org/

 Secções "1.3 – Execution Model" e "1.4 – Memory Model", do "Open MP – Application Programming Interface", v. 4.0 (http://www.openmp.org/wp-content/uploads/OpenMP4.0.0.pdf)

O que é o OpenMP

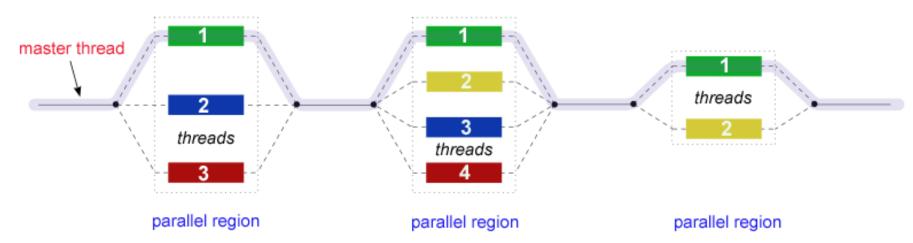
Open Multi Processing

- API para expressar paralelismo multi-threaded e de memória partilhada
- standard mantido pelo OpenMP Architecture Review Board
- Nov.2015 : versão 4.5 (maior parte dos compiladores suporta 4.0)
- Objectivos:
 - normalização (standard)
 - portabilidade
 - fácil utilização

Modelo de execução

 Criação explícita de blocos paralelos de código executados por um grupo (team) de threads

Modelo Fork & Join



- No final de cada bloco:
 - todas as threads sincronizam (barreira implícita)
 - todas as threads excepto a principal deixam de existir

Modelo de execução

```
printf("program begin\n");
N = 1000;
                                  Sequencial
#pragma omp parallel for
for (i=0; i<N; i++)
                                 Paralelo
    A[i] = B[i] + C[i];
                                  Sequencial
M = 500;
#pragma omp parallel for
                                 Paralelo
for (j=0; j<M; j++)
    p[j] = q[j] - r[j];
                                  Sequencial
printf("program done\n");
```

[Seung-Jai Min, Purdue University]

Directivas

• Paralelismo especificado usando directivas embebidas no código #pragma omp <nome directiva> [clásula,...]

Cada directiva aplica-se ao bloco de instruções que se lhe segue
 #pragma omp parallel
 ... // bloco paralelo

```
... // bloco sequencial
```

 O compilador ignora as directivas se não for usada a opção que activa o OpenMP. Exemplo:

```
gcc -fopenmp <filename>
icc -openmp <filename>
```

directiva parallel

```
#pragma omp parallel
{
    ... // bloco paralelo
}
```

- cria um grupo (team) de N threads
- cada uma desta threads executa independentemente o bloco paralelo
- no fim do bloco existe uma barreira (sincronização) implícita: a thread principal só continua depois de todas as outras também terem chegado ao fim do bloco

directiva parallel

```
char *s = "Hello, world!";
#pragma omp parallel
{
   printf("%s\n",s);
}
printf("program done\n");
```

```
>./prog
Hello, world!
Hello, world!
program done
```

directiva parallel

- Quantas threads há num grupo?
 - 1. cláusula num_threads(int)
 #pragma omp parallel num_threads(64)
 - 2. função omp_set_num_threads(int)
 omp_set_num_threads (12);
 - 3. variável de ambiente OMP_NUM_THREADS> export OMP NUM THREADS=8
 - 4. Por omissão: dependente da implementação normalmente igual ao número de processadores disponível para o programa

Funções

#include <omp.h></omp.h>									
Função	Descrição								
<pre>int omp_get_thread_num (void)</pre>	Devolve ID da thread								
<pre>int omp_get_num_threads (void)</pre>	Devolve número de threads actualmente existentes num bloco paralelo								
<pre>void omp_set_num_threads (int)</pre>	Estabelece número de threads a ser criadas no próximo bloco paralelo								
<pre>int omp_get_num_procs (void)</pre>	Devolve número de processadores disponíveis para o programa								
double omp_get_wtime (void)	Devolve um time stamp em segundos								
e muitas mais									

directiva parallel — ordem de execução

```
#include <omp.h>
#pragma omp parallel num_threads(2)
{
   printf("Há %d threads"\n",omp_get_num_threads ());
   printf("Esta é a thread %d\n",omp_get_thread_num());
}
printf("program done\n");
```

```
>./prog
Há 2 threads!
Esta é a thread 0!
program done
Há 2 threads!
Esta é a thread 1!
program done
>_
```

```
>./prog
Há 2 threads!
Há 2 threads!
Esta é a thread 1!
Esta é a thread 0!
program done
>_
```

```
>./prog
Há 2 threads!
Esta é a thread 0!
program done
Há 2 threads!
Esta é a thread 1!
>_
```

Seleccione o *output* possível!

directiva parallel - cláusula nowait

```
#include <omp.h>
#pragma omp parallel
{
  printf("I'm alive!\n");
}
printf("program done\n");
```

```
#include <omp.h>
#pragma omp parallel nowait
{
  printf("I'm alive!\n");
}
printf("program done\n");
```

nowait elimina a barreira (sincronização)
no fim do bloco parallel

```
>./prog
I'm alive!
I'm alive!
program done
>_
```

```
>./prog
I'm alive!
program done
I'm alive!
>_
```

Note que com nowait ambos os *outputs* são possíveis

directiva single

Apenas a primeira thread a atingir o bloco single o executa Todas as threads sincronizam no fim do bloco (barreira implícita)

```
Sequencial
int n;
#pragma omp parallel
{ int tid;
                                   Paralelo
  tid = omp_get_thread_num();
#pragma omp single
  { n = omp_get_num_threads();
    printf ("%d threads\n", n);
                                   Sequencial
  printf (thread %d\n", tid);
                                   Paralelo
printf("program done\n");
                                    Sequencial
```

parallel - ordem de execução

```
#include <omp.h>
#pragma omp parallel num_threads(2) {
   printf("Esta é a thread %d\n",omp_get_thread_num());
   #pragma omp single
     printf("Há %d threads"\n",omp_get_num_threads ());
}
printf("program done\n");
```

```
>./prog
Há 2 threads!
Esta é a thread 1!
Esta é a thread 0!
program done
>_
```

```
>./prog
Esta é a thread 1!
Há 2 threads!
program done
Esta é a thread 0!
>_
```

```
>./prog
Esta é a thread 0!
Há 2 threads!
Esta é a thread 1!
program done
>_
```

parallel - ordem de execução

```
#include <omp.h>
#pragma omp parallel num_threads(2) nowait {
    #pragma omp single
        printf("Há %d threads"\n",omp_get_num_threads ());
    printf("Esta é a thread %d\n",omp_get_thread_num());
}
printf("program done\n");
```

```
>./prog
Há 2 threads!
Esta é a thread 1!
program done
Esta é a thread 0!
>_
```

```
>./prog
Há 2 threads!
program done
Esta é a thread 1!
Esta é a thread 0!
>_
```

```
>./prog
Esta é a thread 0!
Há 2 threads!
Esta é a thread 1!
program done
>_
```

Seleccione o *output* possível!

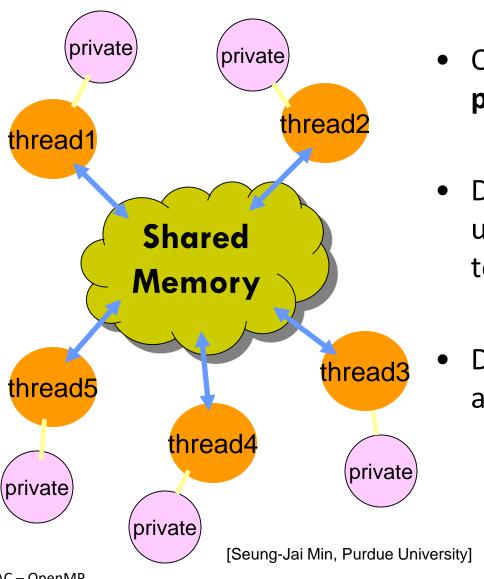
Loop construct: directiva for

```
#pragma omp parallel num_threads(2)
{
#pragma omp for
for (i=0; i<N; i++) A[i] = B[i] + C[i]; }</pre>
```

- deve estar dentro de um bloco parallel
- distribui as iterações do ciclo pelas threads activas no grupo (team) actual:
 - o espaço de iterações (i=0 .. N-1, neste exemplo) é decomposto em subintervalos (chunks) consecutivos;
 - os chunks são distribuídos pelas threads
 - sem informação adicional nada se pode assumir sobre o número ou tamanho dos chunks, nem sobre a sua distribuição pelas threads, excepto de que cada thread será responsável pela execução de pelo menos 1 chunk
- for e parallel podem ser combinadas

```
#pragma omp parallel for num_threads(2)
for (i=0; i<N; i++) A[i] = B[i] + C[i];</pre>
```

Modelo de dados



- Os dados podem ser partilhados ou privados
- Dados partilhados dentro de um grupo são acessíveis a todas as threads desse grupo
- Dados privados são acessíveis apenas à *thread* que os possui

Modelo de dados

Por omissão os dados são partilhados, i.e.,

as variáveis globais a um bloco paralelo são partilhadas

- Variáveis privadas:
 - declaradas dentro de um bloco paralelo
 - explicitamente marcadas como privadas
 - indices dos ciclos associados a uma directiva for

Variáveis globais a um bloco paralelo são partilhadas por omissão

```
main () {
 int
 #pragma omp parallel
       omp_get_thread_num();
  printf("Thread %d\n",tid);
 printf("program done\n");
```

variável partilhada:

as várias threads
escrevem e lêem em
qualquer ordem, sem
controlo de acesso

Resultado indeterminado

Variáveis globais a um bloco paralelo são partilhadas por omissão

```
main () {
  int tid;
    #pragma omp parallel num_threads(2)
    {
        tid = omp_get_thread_num();
        printf("T %d\n" tid);
    }
    printf("program done\n");
    #main () {
            . T0: tid = 0
            . T1: tid = 1
            . T0: escreve "T1"
            . T1: escreve "T1"
            . T0: "program done"
```

Nota: outras ordens de execução são possíveis

• São variáveis privadas:

```
    locais ao bloco

  #pragma omp parallel
  { int i;
  ...}

    explicitamente declaradas com a cláusula private (...)

  int x;
  #pragma omp parallel private (x)

    os índices dos ciclos abrangidos pela directiva for

  int i;
  #pragma omp parallel for
  for (i=0; i<N; i++)
      A[i] = B[i] + C[i];
```

```
main () {
  int tid;
```

Cláusula private: variável privada cada thread tem a sua própria instância local de tid

```
#pragma omp parallel private (tid)
{
  tid = omp_get_thread_num();
  printf("Thread %d\n",tid);
}
printf("program done\n");
```

Declaração dentro do bloco: variável privada

cada thread tem a sua própria instância local main () { de tid #pragma omp parallel int tid; tid = omp_get_thread_num(); printf("Thread %d\n",tid); printf("program done\n");

}

directiva for - data scope

 Apenas são privados os índices dos ciclos associados a uma directiva for

```
int r, c, k;
#pragma omp parallel for private(c,k)
for (r=0; r<N; r++) {
  for (c=0 ; c<N ; c++) {
    for (k=0 ; k<N ; k++) {
       M[r,c] = A[r,k] * B[k,c];
}</pre>
```

Só são privados os índices dos ciclos abrangidos pela directiva!!

directiva for - collapse

 collapse (n) aplica-se a ciclos for aninhados, aumentando o número de iterações disponíveis para execução paralela

```
int i,c;
#pragma omp parallel for collapse (2)
for (i=0; i<N; i++) {
   for (c=0 ; c<M ; c++) {
      M[i,c] = sqrt (M[i,c]); } }</pre>
```

i	0	0	0	0	1	1	1	1	 N-1	N-1	N-1	N-1
С	0	1	•••	M-1	0	1		M-1	 0	1	•••	M-1

chunks são intervalos contíguos neste espaço de N*M iterações, seguindo a ordem sequencial conforme tabelado neste exemplo.

race conditions: o resultado depende da ordem de acesso a dados partilhados

```
int x=0;
#pragma omp parallel num_threads(2)
x = x+1;
```

Caso 1

. *T0:* lê x (valor 0)

. T0: calcula 0+1 = 1

. *T1:* lê x (valor 0)

. T0: escreve x=1

. *T1:* calcula 0+1 = 1

. T1: escreve x=1

Caso 2

. *TO:* lê x (valor 0)

. T0: calcula 0+1 = 1

. *T0:* escreve x=1

. *T1:* lê x (valor 1)

. *T1:* calcula 1+1 = 2

. T1: escreve x=2

directiva critical: apenas uma thread executa esse bloco em cada instante.

```
int x=0;
#pragma omp parallel
    #pragma omp critical
    x = x+1;
```

Se uma *thread* está dentro de uma região crítica, então nenhuma outra *thread* entra nessa região até a *thread* anterior sair: -> a execução das regiões críticas não acontece em paralelo, é **sequencial**

```
int x=0, y=0;
#pragma omp parallel
{
    #pragma omp critical
    x = x+1;
    #pragma omp critical
    y = y+1; }
```

As regiões críticas sem nome são consideradas a mesma região! Se uma *thread* está em x = x+1, então nenhuma outra *thread* entra em y = y+1 e vice-versa

```
Duas regiões críticas distintas.

x = x+1 e y = y+1

podem acontecer em paralelo
```

```
int x=0, y=0;
#pragma omp parallel
{
    #pragma omp critical C1
    x = x+1;
    #pragma omp critical C2
    y = y+1; }
```

directiva atomic: garante que um endereço de memória é acedido de forma atómica. Pode ser vista como uma versão leve de critical.

Só se aplica a operações simples (atómicas).

Não garante que o lado direito da atribuição é avaliado de forma atómica.

```
int x=0;
#pragma omp parallel
    #pragma omp atomic
    x += 10;
```

```
int x=0;
#prayma omp parallel
{
    #pragma omp atomic
    x = 3 * x + 20/x;
}
```

 designa-se por redução uma operação que processa um conjunto de dados para a partir dele gerar um único valor, exemplo, a soma/máximo/produto de todos os elementos de um vector

```
int a[SIZE];
... inicializar a[]
int max=a[0];
#pragma omp parallel for
{
  for (i=0; i < SIZE; i++)
   if (a[i]>max) max=a[1]; }
```

max é uma variável partilhada

muito ineficiente NA verdade a execução é sequencial

```
int a[SIZE];
... inicializar a[]
int max=a[0];
#pragma omp parallel
\{int max\} = a[0];
 #pragma omp for
 for (i=0; i< SIZE ; i++)
   if (a[i]>maxl) maxl=a[i];
 #pragma omp critical
 if (max1 > max) max = max1;
}
```

 A redução é tão comum que o OpenMP inclui uma cláusula específica (mas não para o máximo)

```
int a[SIZE];
... inicializar a[]
int sum=0;
#pragma omp parallel for reduction (+:sum)
{
  for (i=0; i < SIZE; i++)
    sum += a[i]; }</pre>
```

• A cláusula reduction aplica-se apenas a operações associativas.

```
x = x op expr

x = expr op x (excepto subtracção)

x binop= expr

X++; ++X

x--; --x

x - variável escalar

expr - expressão escalar que não refere x

op - +, *, -, /, &, ^, |, &&, ||

binop - +, *, -, /, &, ^, |
```

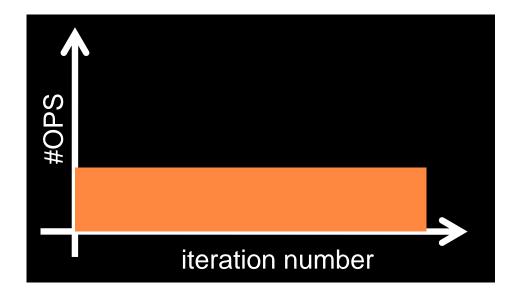
 As operações sobre operandos em vírgula flutuante (float, double) não são associativas:

```
>./prog
float a[SIZE], sum=0.;
                           sum = 1233458.0
... inicializar a[]
#pragma omp parallel for re > . /prog
                           sum = 1233463.0
for (i=0; i < SIZE; i++)
                           >./prog
   sum += a[i]; 
printf ("sum= \%.1f\n", sum)
                           sum = 1233457.0
```

Escalonamento

• Caso 1 - A quantidade de trabalho a realizar é igual para todas as iterações. Exemplo:

```
#pragma omp parallel for
{
  for (i=0; i< SIZE; i++)
   b[i] = a[i]*a[i] + 10. / a[i]; }</pre>
```



Escalonamento

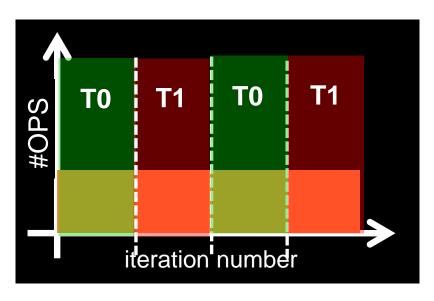
 Caso 2 - A quantidade de trabalho a realizar varia entre iterações. Exemplo:

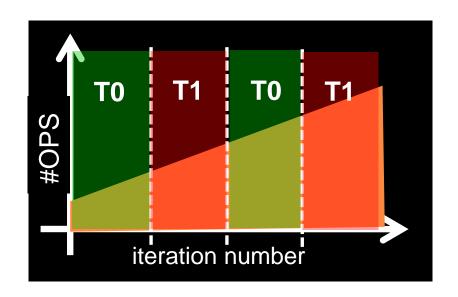
```
#pragma omp parallel for private (j)
 for (i=0; i < SIZE; i++) {
   b[i] = 1.F;
   for (j=2; j<= i; j++)
     b[i] *= j; } }
                         #OPS
                                   iteration number
```

Escalonamento Estático

#pragma omp parallel for schedule(static, <chunksize>)

- O espaço de iterações é dividido em *chunks*, com *chunksize* iterações cada
- Os chunks são atribuídos às threads de forma estática usando round robin, antes da execução do ciclo se iniciar
- Pode resultar em desbalanceamento de carga se a quantidade de trabalho variar entre chunks

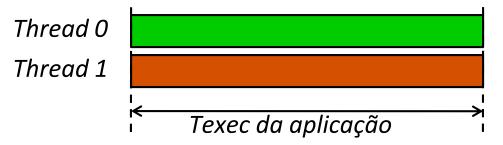




Escalonamento estático

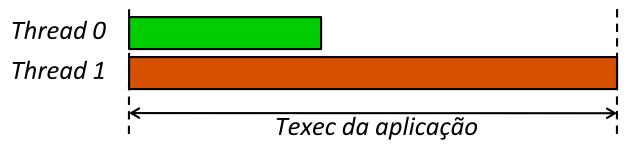
#pragma omp parallel for schedule(static)

1 – carga uniforme para todas as iterações



carga **bem** distribuída

2 - carga variável para diferentes iterações

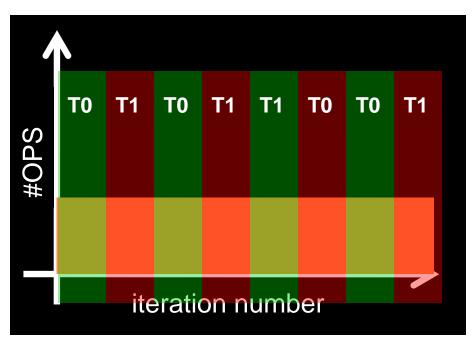


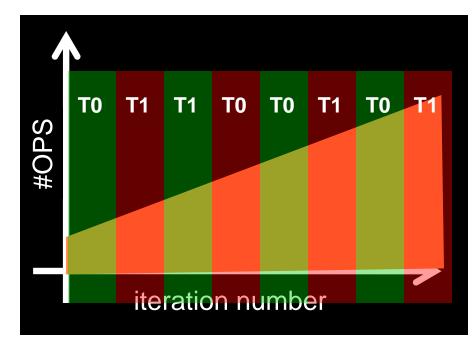
carga **mal** distribuída

Escalonamento dinâmico

#pragma omp parallel for schedule(dynamic)

 O ciclo é dividido em muitos segmentos (chunks), todos com o mesmo número de iterações, e distribuídos pelas threads a pedido

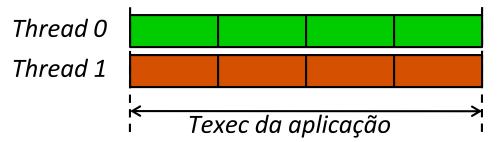




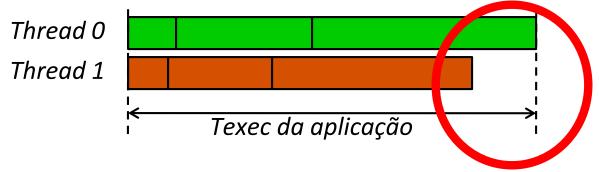
Escalonamento dinâmico

#pragma omp parallel for schedule(dynamic)

1 - carga uniforme para todas as iterações



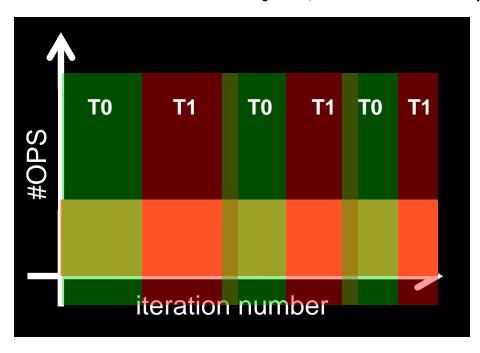
2 - carga variável para diferentes iterações

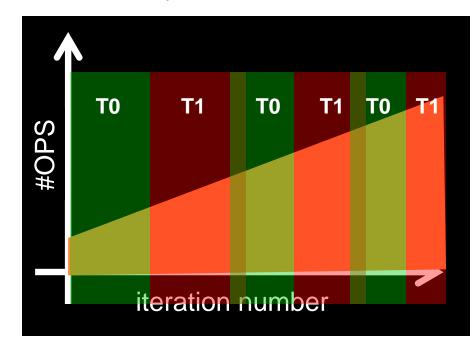


Escalonamento guiado

#pragma omp parallel for schedule(guided)

 O ciclo é dividido em muitos segmentos (chunks), cada vez com menor número de iterações, e distribuídos pelas threads a pedido

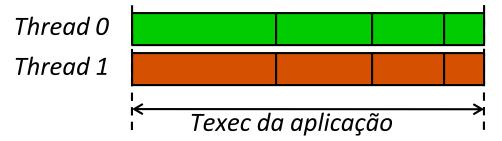




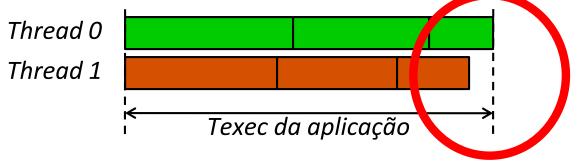
Escalonamento guiado

#pragma omp parallel for schedule(guided)

1 - carga uniforme para todas as iterações

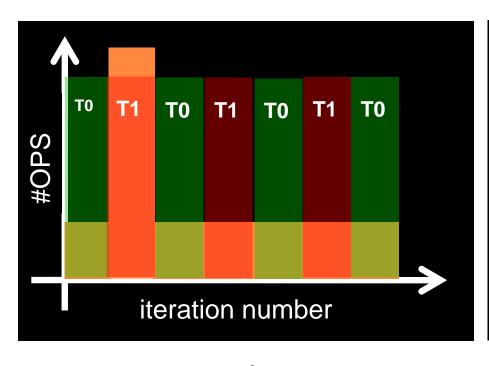


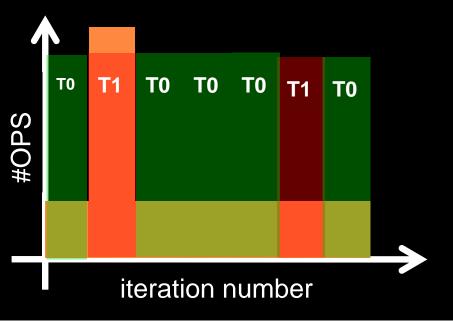
2 - carga variável para diferentes iterações



Escalonamento estático versus dinâmico

Exemplo para carga muito irregular





static

dynamic

desempenho

$$T_{exec} = \#I * CPI / f$$

- Com a programação multithreaded o número de instruções executadas aumenta, devido à gestão do paralelismo
- Como medir o CPI?

Desempenho: como medir o CPI

CPI por processador p

Tende a manter-se constante com a introdução de múltiplos cores

$$CPI_{p} = \frac{\#cc_{p}}{\#I_{p}}$$

CPI global

Tende a manter-se constante com a introdução de múltiplos cores

 $CPI = \frac{\sum_{p=0}^{P-1} \#cc_p}{\sum_{p=0}^{P-1} \#I_p}$

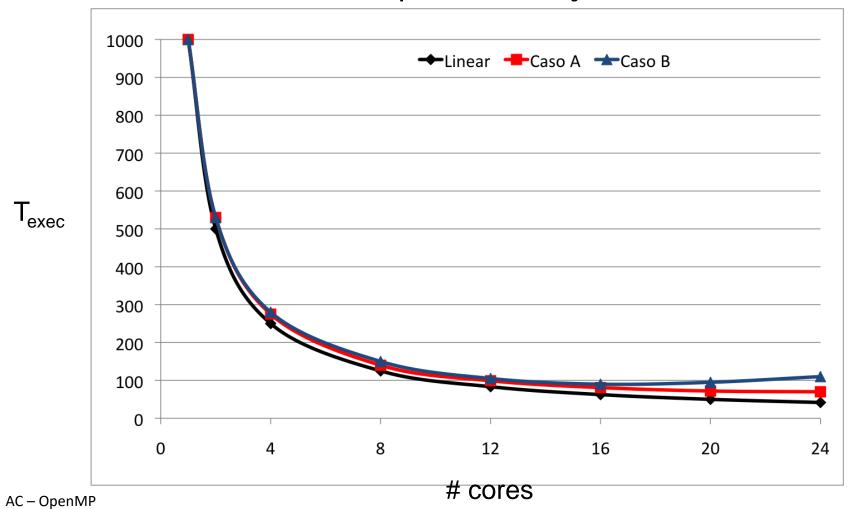
 CPI percepcionado (pelo utilizador)

Tende a diminuir com a adição de múltiplos cores, se o tempo de execução diminuir

$$I_{\text{perceived}} = \frac{\max(\#cc_p)}{\sum_{p=0}^{P-1} \#I_p}$$

desempenho – tempo de execução

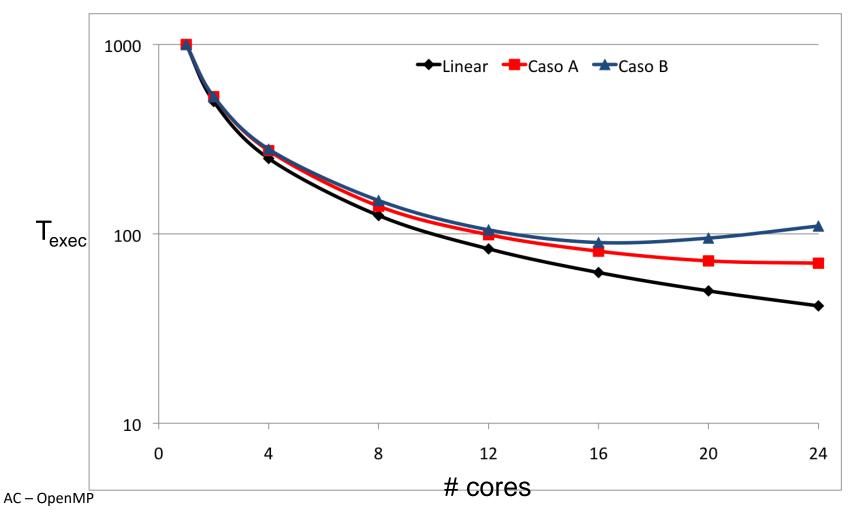
• OBJECTIVO: diminuir o tempo de execução



46

desempenho – tempo de execução

• Escala Logarítmica



desempenho – speed up

$$S_p = \frac{T_1}{T_p}$$

p – número de processadores

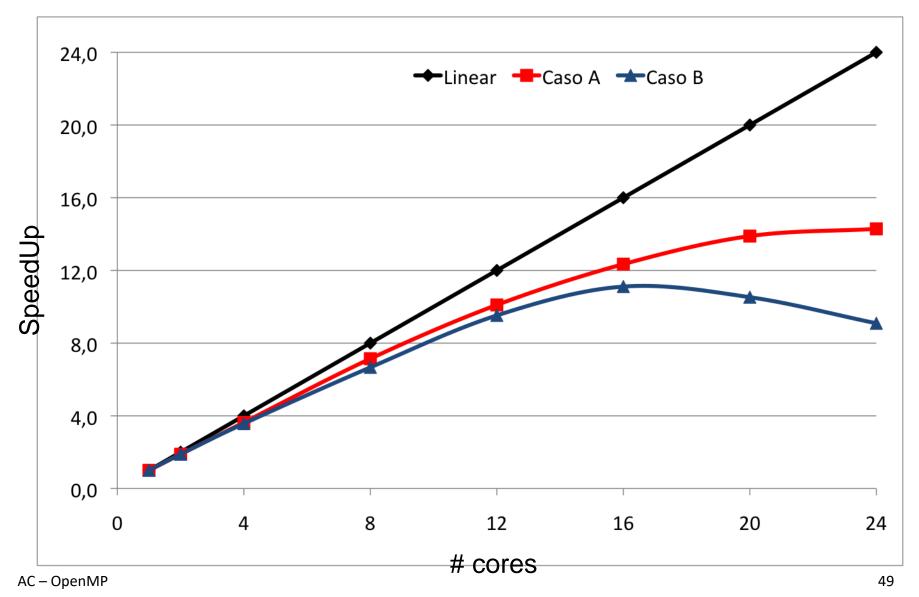
 T_1 – tempo de execução p=1

 T_p – tempo de execução com p processadores

- indica quantas vezes mais rápida é a versão paralela com p processadores relativamente à versão sequencial
- O desafio está na escolha de T₁:
 - deve-se usar o mesmo algoritmo mas apenas 1 processador?
 - deve-se usar o melhor algoritmo sequencial conhecido para aquele problema?

A resposta depende claramente do que se pretende avaliar com este ganho!

desempenho – speed up

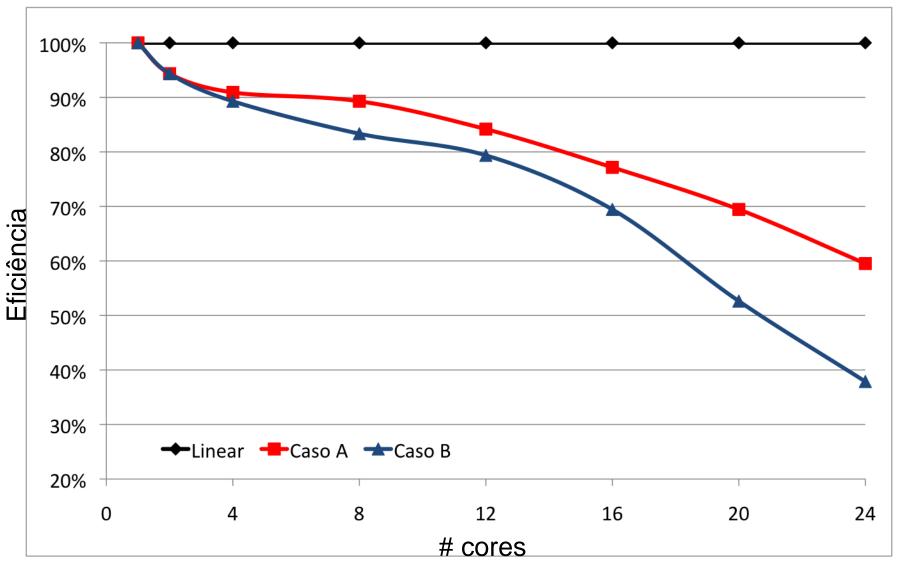


desempenho – eficiência

$$E_p = \int_p^{p-\text{número de processadores}} S_p - \sup_{S_p-\text{speed up com } p \text{ processadores}}$$

- indica em que medida estão os p processadores a ser bem utilizados
- Razão entre o speed up observado e o ideal (=p)
- A utilização total efectiva dos processadores resultaria numa eficiência de 100%

desempenho – eficiência



desempenho

- O speed up observado é inferior ao linear (ou a eficiência é inferior a 100%) devido a vários custos (overheads) associados ao paralelismo:
 - gestão do paralelismo
 - replicação de trabalho
 - distribuição da carga
 - comunicação / sincronização